



De la observación a la causa

Inferencia Causal para Medir el Impacto Real del Turismo en la biodiversidad



Turismo
Secretaría de Turismo




En colaboración con




CONANP
COMISIÓN NACIONAL DE ÁREAS
NATURALES PROTEGIDAS

**CONSERVACIÓN
INTERNACIONAL**
México








Análisis para intervenir, no para predecir

Predecir trata sobre observaciones históricas, nuestros datos resultado del monitoreo, lo que ya paso, mientras que intervenir no solo trata de lo que va a pasar si las cosas siguen igual, sino de medir el impacto de una acción, cambiar el valor de una variable.

La **inferencia causal** nos permite realizar intervenciones que tengan el impacto deseado partiendo de datos, modelos y su análisis.



Los mundos paralelos

Comparar mundos paralelos para descubrir causas.


La estadística tradicional observa cómo se comporta el mundo.

La **inferencia causal** hace algo mucho más poderoso: **compara el mundo que existe con otro mundo posible donde nosotros alteramos una variable.**

Ese mundo alternativo nos permite responder la pregunta más importante de la ciencia: **¿qué pasaría si...?**

Ejemplo:

¿Cómo cambiaría la abundancia de las especies, si modificáramos el flujo de turistas?




Observación vs Intervención

Observar el mundo o intervenir en el

La estadística tradicional describe lo que observa.

La **inferencia causal** intenta averiguar qué sucedería si cambiáramos deliberadamente el valor de una variable del sistema.



El mundo paralelo que nunca podremos observar


Ese mundo que no podemos observar se llama **contrafactual**.

Para saber si una intervención realmente produjo un efecto, necesitaríamos observar **dos versiones del mismo mundo al mismo tiempo**:

- un mundo donde la intervención ocurrió;
- otro donde nunca ocurrió.

Ejemplo:

Necesitaríamos ver simultáneamente la misma área de Conservación con el mismo clima, las mismas especies y las mismas condiciones, pero con dos niveles distintos de turismo.



¿Como funciona el análisis causal?

Ese mundo que no podemos observar se llama **contrafactual**.

Cada decisión que tomamos, crea un único mundo observable. Todos los demás mundos posibles desaparecen.

La **inferencia causal** intenta reconstruir, usando herramientas estadísticas, ese mundo paralelo: el que habría existido si las cosas hubieran sucedido de otra manera.

Comparando ambos mundos podemos aproximarnos, por primera vez, a identificar la causa de los fenómenos.




Construyendo un mundo paralelo

El mundo paralelo es indispensable para construir el modelo causal

Ese mundo paralelo lo construimos al identificar cuales son las variables que causan lo que estamos midiendo. De esta manera construimos artificialmente un grupo de control cuando no podemos tener uno en la realidad.

Necesitamos preguntarnos ¿Hay algo mas que este cambiando al mismo tiempo que la causa que estoy investigando?

El modelo causal que construimos tiene como objetivo recrear el grupo de control que la naturaleza no nos dio.




Construyendo un Mundo Paralelo y encontrando las causas

Con la metodología de la **Inferencia Causal**, podemos construir ese mundo paralelo, siguiendo estas etapas :

- Identificar el efecto que nos interesa
- Identificar las posibles causas de ese efecto
- Dibujar la estructura causal (que variable causa a otras y en que orden)
- Generar los protocolos para recolectar datos en campo y si es necesario en oficina (mapas)
- Recolectar los datos
- Analizar la información con las herramientas estadísticas de la **inferencia causal**.

INFLUENCIA EN ECOSISTEMAS



El proyecto Kuxatur

Objetivo principal: Integrar criterios de conservación de la biodiversidad en el sector turístico de México.

Propósito: Atender las causas de la pérdida de biodiversidad y degradación ambiental originadas por el turismo, promoviendo un modelo de desarrollo sustentable.

Es el primer proyecto del Fondo para el Medio Ambiente Mundial (GEF) otorgado al sector turístico en México.

La Secretaría de Turismo de México lo ejecuta en colaboración con el Fondo Mundial para la Naturaleza (WWF), Amigos de Sian Ka'an, Conservación del Territorio Insular Mexicano (ISLA) y es implementado por PNUD.


El proyecto busca solucionar la falta de salvaguardas de conservación, los incentivos financieros inadecuados y la ausencia de modelos de turismo sustentable replicables.



Componente de la plataforma


Esta plataforma se compone de tres componentes clave que trabajan en conjunto para facilitar la recolección y el análisis de datos:

- **Una aplicación móvil** para dispositivos Android e iOS que permite la recolección de datos en el campo.
- **Un programa de escritorio** (Windows o macOS) que facilita la descarga, el análisis y la exportación de los datos recogidos en la aplicación.
- **Una base de datos y funciones en la nube** (Amazon Web Services) que almacena de forma segura toda la información y gestiona los permisos de acceso de los usuarios.



Red de monitoreo

- El coordinador general (**K00**) distribuye el **programa de escritorio** y las credenciales de acceso a los coordinadores de cada territorio (**K01, K02, K03**).
- El coordinador de monitoreo de cada territorio da de alta a los monitores
- El coordinador general y/o coordinadores de cada territorio digitalizan los protocolos de monitoreo.
- Los Monitores instalan la App, realizan el monitoreo y envían los datos.





Mapa



FUNCIONES GENERALES

- Alta de usuarios
- Diseño de Protocolo
- ✓ Descargar registros
- Q Consultar registros
- Análisis exploratorio
- Subir cartografía

FUNCIONES AUXILIARES

- ⚠ Reseteo Base de Dat...



Estatus: Descargando base de datos

Consultar registros

Filtros de selección

Seleccione Estado

Todos

Seleccione protocolo

Seleccione un protocolo

Seleccione fechas

AAAA-MM-DD

AAAA-MM-DD

Otro protocolo

Otro protocolo

Por clave de monitor

PSCO-AAA-NNPPMM###-CCC

Realizar consulta

Descargas de selección

Descargar CSV

Registros: 17

V	ESTADO	Protocolo	Monitor	Fecha	Validado
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-255-1	2025-07-14	si
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-508-4	2025-07-14	si
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-823-2	2025-07-14	si
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-933-0	2025-07-14	si
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-991-3	2025-07-14	si
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-015-13	2025-07-16	no
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-015-14	2025-07-16	no
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-089-8	2025-07-16	si
👁	K02	PROTOANALISISDATOS	PSCO-K02-USUAR398-LOC-128-9	2025-07-16	si

10:49 77

 kuxatur

Protocolos

Protocolo

Protocolo de prueba

Protocolo de prueba

Descripción

Metodología

Sitio de muestreo

Localidad

Nombre del sitio

Fotografía del sitio



10:50 76

 kuxatur

Temporalidad y coordenadas

Coordenada

Haga click aquí...

Fecha

Hora inicio

Hora término

Variables ambientales

Tipo de vegetación

Seleccione opción

Actividades humanas

Agricultura

Seleccione opción

10:50 76

 kuxatur

Conteos

Especies observadas +

Especies observadas # 1

Especies observadas # 2

Especies observadas # 3

Especies observadas # 4

Especie

No. individuos

Coordenada

Haga click aquí...

GUARDAR REGISTRO DE INDIVIDUO

Análisis exploratorio de datos

Detección de valores faltantes

El proceso inicia con el **análisis de valores faltantes**, mostrará una tabla con el conteo y porcentaje de valores faltantes para cada variable, el usuario debe seleccionar un método de imputación para continuar el análisis.

¿Qué es un valor faltante?

Es un dato ausente donde se esperaba un valor

¿Por qué detectarlos?

Para comprender la calidad del conjunto de datos, evitar sesgos y tomar decisiones informadas sobre cómo tratarlos (eliminarlos, imputarlos o conservarlos).

Reglas generales:

- **< 5% de valores faltantes:** suele considerarse manejable. Puede imputarse sin distorsionar demasiado.
- **5–15% de faltantes:** requiere análisis más cuidadoso; imputación con métodos avanzados o eliminar variables si es necesario.
- **> 15% de faltantes:** puede ser problemático; considerar si la variable es útil o debe eliminarse.

The screenshot shows the 'Monitoreo biológico Kuxatur' web application. On the left is a sidebar with the Kuxatur logo and a menu of functions. The main content area is titled '1. Análisis de Valores Faltantes' and displays a table of missing values for various variables. Below the table is a dropdown menu to select an imputation method and a blue button to apply it. The status bar at the bottom indicates 'Estatus: Consulta terminada'.

FUNCIONES GENERALES

- Alta de usuarios
- Diseño de Protocolo
- Descargar registros
- Consultar registros
- Análisis exploratorio
- Subir cartografía

FUNCIONES AUXILIARES

- Resetear Base de Dat...

Logos: Turismo, GEF, amig@s, ISLA, WWF, CONANP, Conservación Internacional.

1. Análisis de Valores Faltantes

Valores Faltantes por Variable:

Variable	Valores Faltantes	% Faltantes
Fecha	0	0.00%
Tiempo meteorológico	0	0.00%
Tipo de vegetación	0	0.00%
Distancia a casas (metros)	0	0.00%
Distancia a caminos (metros)	0	0.00%
Pastoreo	1	5.88%
Tala	0	0.00%
Especie	0	0.00%
No. individuos	0	0.00%
Coordenada	0	0.00%
Actividad	0	0.00%

-- Selecciona -- Selecciona Método de Imputación de Valores Faltantes:

Aplicar Imputación

Estatus: Consulta terminada

Análisis exploratorio de datos

Detección de valores atípicos (outliers)

¿Qué es un valor atípico?

Un valor muy alejado de la distribución central.

¿Por qué detectarlos?


Para identificar errores, datos extremos reales o variabilidad natural.

Reglas generales:


- < 5% outliers: usualmente datos naturales, no problemático, 10% outliers: posible problema o datos mezclados, Outliers muy alejados: revisar si son errores o casos especiales.

Impacto en análisis: Outliers pueden distorsionar modelos clásicos (regresión, correlación).

Distribución de AbundanciaTotalAves



Distribución de AbundanciaTotalAves



Outliers Detectados (Método Z-Score)

Variable	Media	Desviación Estándar	# Outliers (Z > 3)	% Outliers
TamanoParqueHa	74.88	44.48	0	0.0%
NumeroEspeciesAves	20.04	6.82	1	0.8%
AbundanciaTotalAves	15.03	11.65	1	0.8%
CoberturaArboreaPct	56.58	22.36	0	0.0%
DistanciaCentroUrbanoKm	18.52	10.72	0	0.0%
AlturaPromedioVegetacionM	17.32	8.02	0	0.0%

Se detectaron outliers. Selecciona un método de imputación:

-- Selecciona --

Aplicar Imputación a Outliers

Análisis exploratorio de datos

Relaciones Bivariadas

¿Qué es?

Incluye análisis y visualizaciones que exploran las relaciones entre una variable numérica y una categórica (boxplots), o entre dos variables categóricas (tablas de contingencia). También se observa la correlación entre variables predictoras y la variable resultado.


¿Qué observar?

- **Patrones de asociación** entre variables categóricas y numéricas (ej., diferencias de medias entre grupos en un boxplot).


Toma de decisiones:

- Si un predictor tiene **fuerte correlación positiva o negativa con la variable resultado**, puede ser un **buen candidato para el modelo**.

Boxplot de AbundanciaTotalAves por grupos de TipoVegetacion



Boxplot de AbundanciaTotalAves por grupos de UsoSueloAdyacente



Análisis exploratorio de datos


Relaciones entre Variables Numéricas (Gráfico de Dispersión)

¿Qué es?

Es una visualización que muestra la relación entre dos variables numéricas. Se utilizan puntos dispersos para representar las observaciones, junto con una línea de regresión lineal (relación recta) y una línea LOESS o SPLINE (ajuste suave que puede revelar relaciones no lineales).

¿Qué observar?

- **Linealidad vs. No linealidad:** Si los puntos siguen una línea recta (relación lineal) o si la línea LOESS se curva (relación no lineal).
- **Homocedasticidad vs. Heterocedasticidad:** Si la dispersión de los puntos alrededor de la línea es constante (homocedasticidad) o variable, como en forma de embudo (heterocedasticidad).
- **Toma de decisiones:**
 - Si la línea LOESS se aleja de la recta, indica una **relación no lineal**.
 - Si la dispersión de puntos se ensancha o estrecha a lo largo del eje x, sugiere **heterocedasticidad**.



Uso de la herramienta de análisis causal

Facilitando el análisis y la interpretación de resultados

Esta herramienta de escritorio está diseñada para estimar el efecto causal que tiene una variable sobre otra, aislando el impacto de factores de confusión mediante modelos de regresión lineal múltiple (OLS). A diferencia de una correlación simple (que solo nos dice si dos cosas cambian juntas), el análisis causal intenta responder a la pregunta: "Si yo obligo a que la variable A cambie, ¿cuánto cambiará la variable B, manteniendo todo lo demás constante?".

Pipeline Causal

1. Seleccionar CSV
Choose File data3.csv

2. Tratamiento (Causa)
indice_biodiversidad

3. Resultado (Efecto)
inversion_anual

5. Método de Estimación
Regresión Lineal Estándar (OLS)

4. Asignar Roles Causales

indice_biodiversidad	Personal	Grupos_Individual	senderismo_picnic	visitantes_año
Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado
promedio_familias	owns_ev	superficie	inversion_anual	
Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado	

Ejecutar Análisis Causal

Sube un archivo CSV y configúralo en el panel izquierdo.

Modelo Causal (DAG)
Este diagrama se genera en tiempo real basándose en los roles asignados.

indice_biodiversidad

Auditoría y Estructura de Datos

De la Información original al Modelo Causal

Carga Inteligente: Importación de archivos .csv con detección automática de encabezados y separación de tipos de datos (numéricos vs. texto) .

Pre-procesamiento Automatizado: Transformación de variables categóricas mediante One-Hot Encoding para su uso en modelos matemáticos .

Inyección de términos polinomiales cuadráticos (X²) para capturar relaciones no lineales complejas .

Visión General del Dataset: Verificación inmediata de dimensiones (filas/columnas) y tipos detectados (number/string) para asegurar la integridad antes del cálculo .

Pipeline Causal

1. Seleccionar CSV

Choose File data3.csv

2. Tratamiento (Causa)

indice_biodiversidad

3. Resultado (Efecto)

inversion_anual

5. Método de Estimación

Regresión Lineal Estándar (OLS)

4. Asignar Roles Causales

indice_biodiversidad	Personal	Grupos_Individual	senderismo_picnic	visitantes_año
Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado
promedio_familias	owns_ev	superficie	inversion_anual	
Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado	Ignorar / No relacionado	

Ejecutar Análisis Causal

Sube un archivo CSV y configúralo en el panel izquierdo.

Modelo Causal (DAG)

Este diagrama se genera en tiempo real basándose en los roles asignados.

indice_biodiversidad


Configuración de Variables

Definiendo la Causa y el Efecto

Tratamiento (La Causa - X): La variable cuyo impacto directo se desea medir .
Requisito: Debe ser numérica (ej. codificar categorías como 0 y 1).

Resultado (El Efecto - Y): La métrica que se espera sea afectada por el tratamiento .
Requisito: Debe ser una variable numérica y continua.

El Salto Conceptual: Transicionamos del aprendizaje supervisado tradicional ($E[Y|X]$) a la capacidad de entender qué pasaría si intervenimos en el sistema mediante el operador $do(X)$.



Cuantificación y Significancia del Efecto


El Veredicto Causal: Magnitud, Certeza y Robustez

ATE Ajustado (Coeficiente β_1): Representa el Efecto Causal Total. Indica cuánto cambia el Resultado por cada unidad adicional de Tratamiento tras cerrar todas las "puertas traseras".

P-value (Significancia): La probabilidad de que el efecto sea puro azar. Un valor < 0.05 confirma que el hallazgo es estadísticamente significativo.

Intervalo de Confianza (95%): Rango de valores donde reside el efecto real. Calculado con estimadores robustos (Huber-White) para garantizar que sea conservador e insesgado ante datos complejos.

E-value (Análisis de Sensibilidad): Métrica de "resistencia". Indica qué tan fuerte tendría que ser una "variable fantasma" no medida para anular nuestro hallazgo




Análisis de Sensibilidad (E-value)

Blindaje ante lo Desconocido: El E-value como Prueba de Estrés

La Variable Fantasma: Cuantifica qué tan fuerte tendría que ser una variable no observada para anular la significancia del efecto causal hallado.

Métrica de Resistencia: Evalúa la robustez del hallazgo frente al riesgo de haber omitido una variable crítica en el diseño.

Criterio de Interpretación: E-value Alto (> 2.0): Hallazgo robusto y "blindado"; se requeriría un factor externo muy potente para derribar la conclusión. E-value Bajo (cercano a 1.0): Hallazgo frágil; cualquier pequeño factor no medido podría invalidar el resultado.



Diagnóstico de Integridad y Ajuste

Auditoría de Residuos: ¿Es el Modelo Estructuralmente Sano?


Observado vs. Predicho: Verificación de la capacidad explicativa. Los puntos deben agruparse a lo largo de una línea diagonal de 45°; una dispersión circular indica que el modelo no captura el fenómeno real.

Gráfico de Residuos (Ruido Blanco):

Visualización del error ($Y_{\text{real}} - Y_{\text{predicho}}$). Buscamos "estática de televisor": una nube aleatoria sin patrones definidos alrededor de la línea cero.

Señales de Alerta (Sesgo de Especificación):


Forma de Embudo: Indica heterocedasticidad (la varianza del error no es constante). Patrones en "U" o Curvaturas: Indican que la relación no es lineal o que falta una variable clave en el DAG.



Democratizando la Inferencia: Integración con IA

Traduciendo matemáticas complejas en narrativas estratégicas


- **Interpretar coeficientes**, sesgos de confusión, P-values y E-values requiere entrenamiento especializado.
- **Para cerrar la brecha** entre el modelo matemático y los tomadores de decisiones, la plataforma integra un Compilador de Prompt Engineering.
- **Al finalizar un modelo**, el sistema recolecta todos los resultados estadísticos, las validaciones de robustez y las interacciones, y genera un reporte de texto plano estructurado.
- **Con el botón "Copiar al Portapapeles"**, el usuario inyecta este contexto en modelos fundacionales (ChatGPT o Gemini) para que actúen como científicos de datos personales, explicando las causas y efectos en lenguaje natural y accionable.



El Concepto de Puerta Trasera (*Backdoor Path*)

Cuando la causa aparente no explica el resultado


En la inferencia causal, una **puerta trasera** es un camino indirecto que conecta la causa con el efecto a través de una tercera variable no considerada. En nuestra analogía, observamos que el perro aparece fuera de casa cada mañana (Efecto). Aunque cerremos la puerta principal (Causa aparente), el resultado sigue ocurriendo porque existe una **variable omitida**: un camino oculto que no estamos viendo



Identificando el Confundidor

La pregunta clave: "¿Hay algo más?"

Para resolver el misterio, debemos ir más profundo y preguntar: "**¿Hay algo más que explique esto?**". El dueño comienza a cerrar todas las puertas visibles, pero el perro sigue escapando. Esto demuestra que existe un **confundidor** (una variable) que está afectando el resultado. En este caso, el dueño descubre la puerta más pequeña, la cual ha estado permitiendo que el perro salga sin que nadie lo note.



Cerrando la Puerta Trasera

Aislando el efecto causal real

Para medir un efecto causal con precisión, es necesario "**cerrar**" las **puertas traseras** controlando las variables que las originan. Al encontrar la puerta y cerrarla, el dueño finalmente "controla" la variable que sesgaba su observación. Si el perro ya no amanece fuera, se ha logrado el estado de **ausencia de confusión**, donde hemos aislado la verdadera relación entre nuestras acciones y el resultado.

